

Redes Neuronales


TP Mate III - Fariña Espinosa Ximena Anahí Milagros
Docentes: J. Bompensieri - T. Prudente

Análisis general de datos:

Columnas de la base de datos:

Información basica del track	Nombre	¿Qué representa?	Tipo de variable
	track_name	nombre del track	categorica
	artist(s)_name	nombre de (los) artista(s)	categorica
	artist_count	cantidad de artistas	discretas
	released_year	año del release	discreta
	released_month	mes del release	discreta
	released_day	día del release	discreta
Métricas de streaming	in_spotify_playlists	cantidad de playlist en las que aparece	discreta
	in_spotify_charts	número que ocupa en los charts de spotify	discreta
	streams	cantidad de reproducciones	discreta
	in_apple_playlists	cantidad de veces que aparece en playlist de apple	discreta
	in_apple_charts	número que ocupa en los charts de apple	discreta
	in_deezer_playlists	cantidad de veces que aparece en playlist de deezer	discreta
	in_deezer_charts	número que ocupa en los charts de deezer	discreta
	in_shazam_charts	cantidad de veces que aparece en playlist de shazam	discreta
Atributos musicales	bpm	(beats per minute) es el tempo de la canción	discreta
	key	tonalidad de la canción	categorica
	mode	modo de la canción	categorica
	danceability_%	potencial de la canción para el baile	continua
	valence_%	positividad del contenido musical de la canción	continua
	energy_%	nivel de energía percibido en la canción	continua
	acousticness_%	nivel de sonido acústico percibido en la canción	continua
	instrumentalness_%	proporción de contenido instrumental de la canción	continua
	liveness_%	presencia de elementos que denoten que fue grabada en vivo	continua
	speechiness_%	porcentaje de contenido hablado presente en la canción	continua
	cover_url	url de la portada de la canción	categorica

Análisis de correlaciones:



Analizando los resultados de la matriz, podemos observar una mayor correlación positiva entre los campos *in_spotify_playlists*, *in_apple_playlists*, *in_deezer_playlists* y el número de streams, por lo cual, serian los campos más relevantes a la hora de entrenar a nuestra red neuronal.


Análisis de factibilidad:

Considero que es factible entrenar un modelo con este set de datos, ya que tenemos una columna objetivo clara, y varias otras columnas que contribuyen al entrenamiento del modelo para predecir los resultados.




Lo que intenta predecir la red, es si una canción supera los 100 millones de streams.

Datos atípicos y limpieza de datos:

Veamos los gráficos de distribución de los datos, en las columnas relevantes para el entrenamiento de nuestra red neuronal (in_spotify_playlists, in_apple_playlists, in_deezer_playlists) observamos que los datos presentan cierta asimetría.



Se decide eliminar los outliers usando la técnica de percentile ya que los datos muestran una fuerte asimetría hacia la derecha. De esta forma, esta técnica nos ayuda a no perder mucha cantidad de datos, dado a que reemplaza los valores atípicos por valores dentro del rango y, además, nos permite ajustarnos a la asimetría que presentan los datos.



Transformaciones preliminares:

- Se decide realizar la normalización de los datos ya que es recomendable para un mejor aprendizaje de la red neuronal.
- Además, se convierte el valor de la columna objetivo 'streams' a ceros y unos dependiendo si superan el umbral de los 100 millones.


Desarrollo de la red neuronal:

Arquitectura:

La red neuronal desarrollada, cuenta con 3 entradas, una capa oculta que contiene 8 neuronas y una capa de salida.

La función de activación elegida para la capa oculta, es ReLU ya que va a transformar cualquier valor negativo en 0, lo cual ayuda a no detener el entrenamiento de la red.


Para la capa de salida se utiliza Logistic, que comprime los valores de salida entre 0 y 1, y, debido a que nuestra red neuronal es de clasificación, es la función de salida más conveniente.



Análisis de overfitting:

Podemos observar que a lo largo de los ciclos, la precisión y la pérdida se “estancan” lo cual es una señal de posible overfitting, a pesar de haber implementado algunas formas de mitigar esto, como agregar dropout y regularización, probando diferentes configuraciones, modificando la cantidad de neuronas de la capa oculta y agregando una capa más, no se consigue mitigar el sobreajuste, por lo cual, una posible causa sea la cantidad de datos que tenemos disponibles para el entrenamiento de la red.

También se puede observar que a partir de los mil ciclos la red llega a su máximo de aprendizaje y luego queda relativamente constante.




- Cantidad de datos de entrenamiento: 568
- Cantidad de datos de prueba: 284

#	Epoch	#	Training Loss	#	Training Accuracy	#	Validation Loss	#	Validation Accuracy
	0		1.602		8.398		8.134		1.866
	100		1.733		8.398		1.801		8.112
	200		1.594		8.398		168		8.112
	300		1.508		8.398		1.608		8.112
	400		1.448		8.415		1.566		8.112
	500		1.411		8.415		1.541		809
	600		1.383		8.415		1.514		809
	700		1.351		8.433		1.492		8.112
	800		1.336		8.433		1.483		8.112
	900		1.326		8.433		1.475		809
	1000		1.315		8.451		1.474		809
	1100		133		8.415		1.469		809
	1200		1.307		8.433		1.471		809
	1300		1.331		8.398		1.461		8.068
	1400		132		8.415		1.465		809
	1500		1.303		8.451		1.471		809
	1600		132		8.415		1.467		8.068
	1700		132		8.415		1.466		809
	1800		1.308		8.451		1.476		8.112
	1900		1.315		8.451		147		809

Comparación con scikit-learn:

Una vez implementada la red en scikit learn no logro llegar a resultados parecidos utilizando una configuración relativamente similar, creo que esto en parte puede deberse al uso de dropout en la red manual. Más allá de eso, tampoco logro tener en esta red resultados consistentes entre ejecuciones.



Conclusión:

A lo largo del desarrollo de las redes, tanto en scikit-learn cómo desde cero, aprendí que el pre procesamiento de datos es muy importante a la hora de entrenar las redes, ya que no vamos a obtener cierta consistencia ni los mismos resultados, si utilizamos datos pre procesados o no. Con respecto al desarrollo de la red manual, creo que a pesar de representar más trabajo a la hora de escribir código, también nos da la flexibilidad de mitigar problemas como el overfitting con más herramientas, mientras que la librería, si bien nos brinda algunas, tiene sus limitaciones.